



Informe Final (100 %) Proyecto SupaClock



Proyecto: SupaClock

Integrantes: Tomás Avendaño, Benjamín Sepúlveda, Pablo Uribe

Fecha: 10 de julio de 2026

Índice

Resumen ejecutivo	4
1. Descripción del proyecto	6
1.1. Contexto y motivación	6
1.2. Alcance del proyecto	6
2. Requerimientos y especificaciones	7
2.1. Requerimientos funcionales	7
2.2. Requerimientos no funcionales	7
2.3. Requerimientos éticos y regulatorios	8
3. Prototipo final	9
3.1. Descripción del prototipo y experiencia de uso	9
3.2. Análisis de cumplimiento de especificaciones	10
3.3. Lista de materiales y análisis de costo	11
4. Diagrama de bloques de bajo nivel	14
4.1. Diagrama actualizado al estado final	14
4.2. Especificaciones por bloque e interconexiones	15
5. Implementación y resultados	17
5.1. Arquitectura de firmware y particionamiento de tareas	17
5.2. Sensores y adquisición de señales	18
5.3. Procesamiento local: Pan-Tompkins y pasos por FFT	18
5.4. Machine Learning on-device: HAR CNN 1D	20

5.5. Aplicación móvil y <i>backend</i>	23
5.6. Mecánica y PCB Carrier v4	23
5.7. Consumo, autonomía y gestión de energía	24
5.8. Validación biométrica frente a referencias	25
5.9. Resultados cuantitativos consolidados	26
6. Análisis de impacto de las soluciones y estándares	27
6.1. Aplicaciones e impacto socioeconómico, ambiental y en salud	27
6.2. Riesgo eléctrico: análisis ECMA-287 punto 3	28
6.3. Estándares relacionados con el área del proyecto	29
6.4. Referencias y fuentes técnicas	31
7. Conclusiones y trabajo futuro	32
7.1. Cumplimiento del alcance planteado	32
7.2. Lecciones aprendidas	32
7.3. Trabajo futuro	32
A. Anexos: extractos de código y tablas	37
A.1. Extracto del pinmap centralizado (<code>include/supaclock_pinmap.h</code>)	37
A.2. API pública del HAR CNN 1D (<code>lib/har_cnn1d/har_cnn1d.h</code>)	37
A.3. Snippet de inferencia HAR sobre ventana IMU	38
A.4. Extracto del algoritmo FFT de pasos (<code>lib/step_algorithm/step_algorithm.c</code>)	38
A.5. Repositorio del proyecto	39

Índice de figuras

1. Prototipo cerrado en detalle. La carcasa se atornilla con cuatro pernos M3 y expone las aberturas alineadas para los sensores biométricos.	9
2. Vistas principales de la aplicación móvil Flutter de SupaClock.	10
3. Diagrama de bloques de bajo nivel de la unidad final	15
4. Particionamiento FreeRTOS del firmware final	17
5. ECG con detección de picos R	19
6. Detección FFT de pasos	20
7. Arquitectura CNN 1D HAR	21
8. Matriz de confusión HAR	22
9. PCB Carrier v4 fresada y poblada. Ambas caras usan pistas de 0,25 mm compatibles con el ProtoMat S64.	24
10. Caracterización de la autonomía del prototipo cerrado.	25

Índice de cuadros

1. Requerimientos funcionales de SupaClock y especificaciones cuantitativas asociadas.	7
2. Requerimientos no funcionales y métricas objetivo.	8
3. Análisis de cumplimiento de especificaciones sobre el prototipo cerrado. Los detalles de cada medición se documentan en §5.	11
4. Lista de materiales del prototipo final SupaClock. Precios en CLP a julio de 2026.	12
5. Gastos de desarrollo, repuestos e imprevistos acumulados durante el proyecto SupaClock. Precios en CLP.	13

6.	Especificaciones e interconexiones detalladas por bloque de la unidad final.	16
7.	Recall y precisión por clase del clasificador HAR.	22
8.	Consumo típico por subsistema en operación y en modo de bajo consumo, según los datasheets correspondientes.	24
9.	Comparación de consumo de corriente sobre batería entre el prototipo C3 SuperMini y el actual XIAO ESP32-S3 en tres escenarios operativos.	25
10.	Validación biométrica del prototipo cerrado frente a instrumentos de referencia.	26
11.	Resumen de resultados cuantitativos del prototipo final.	26
12.	Análisis de riesgos eléctricos según ECMA-287, punto 3 [1].	29

Resumen ejecutivo

SupaClock es un dispositivo *wearable* biométrico de muñeca diseñado, fabricado, programado y validado íntegramente por el Grupo 10 como proyecto capstone del curso IEE2913 — Diseño Eléctrico (Capstone). El sistema combina cinco cadenas de medición (temperatura corporal, frecuencia cardíaca, oxigenación, electrocardiograma monoderivación y actividad física) sobre una plataforma unificada: un microcontrolador Sseed XIAO ESP32-S3 [2, 3] montado en una PCB *carrier* propia fresada en el FabLab, alojado en una carcasa impresa en PLA cerrada con tornillos M3, con una aplicación móvil Flutter [4, 5] y un *backend* Firebase Firestore [6] que registran, sincronizan y visualizan las señales biométricas del usuario. El diferenciador técnico central del prototipo es que la clasificación de actividad física ocurre **a bordo del reloj mediante una red neuronal convolucional 1D en formato float32 sobre TensorFlow Lite Micro** [7, 8], sin depender de *cloud* para su operación cotidiana.

Esta iteración final cierra los objetivos planteados en las etapas anteriores. Se completó la migración desde el ESP32-C3 al ESP32-S3 aprovechando su PSRAM externa para alojar la arena del intérprete TFLite; se entrenó e integró un modelo HAR CNN-1D de cuatro clases (*rest, walk, run, stairs*) con una exactitud global del 95,0 % sobre el conjunto de validación; se fabricó y validó la unidad cerrada con dimensiones finales de $17 \times 74 \times 93$ mm y 115 g de peso incluyendo batería LiPo de 300 mAh; se caracterizó la autonomía mediante curvas reales de descarga y carga; y se contrastó la exactitud biométrica del reloj contra un Samsung Galaxy Watch 4 (HR/SpO₂/ECG) [9], un termómetro digital de contacto (temperatura) y conteo manual (pasos), obteniendo desviaciones inferiores al 2 % en las cuatro métricas principales.

Este informe se organiza en nueve secciones. La sección 1 presenta el proyecto y su motivación; la sección 2 enuncia los requerimientos funcionales, no funcionales y regulatorios adoptados; la sección 3 describe el prototipo, su experiencia de uso, el cumplimiento de las especificaciones y el análisis de costo; la sección 4 presenta el diagrama de bloques de bajo nivel actualizado y la tabla de especificaciones por bloque; la sección 5 detalla la implementación por subsistema con resultados cuantitativos; la sección 6 analiza el impacto social, económico, ambiental y ético del dispositivo junto con la revisión de estándares aplicables (ECMA-287, Bluetooth Core, IEEE 11073-10406, IEC 60601-1, USB-C, RoHS-2, IEC 62133-2); la sección 7 cierra con las conclusiones y el trabajo futuro. Los anexos contienen extractos representativos del código firmware, tablas de soporte y el enlace al repositorio público del proyecto.

Entregables producidos. La entrega final consolida los siguientes componentes:

- **Firmware ESP-IDF** sobre XIAO ESP32-S3 con arquitectura modular en la biblioteca `supaclock_app`, PSRAM, USB CDC nativo, *deep sleep* activo y gestión dinámica de energía.
- **Modelo HAR CNN-1D** de cuatro clases entrenado con datos capturados por el propio dispositivo, cuantizado a *float32*, ejecutado en TFLite Micro con arena de 512 KB en PSRAM y latencia típica < 10 ms.
- **Algoritmo de pasos por FFT** con ventana Hann de 128 muestras a 50 Hz sobre `esp-dsp` [10], filtrado por banda 1,0–2,5 Hz e histéresis temporal.
- **Pipeline ECG**: adquisición con ADC/DMA a 500 Hz, transmisión por BLE NimBLE [11] y procesamiento Pan-Tompkins [12] en el lado de la aplicación móvil.
- **PCB Carrier v4**: placa integradora de dos caras compatible con el ProtoMat S64 del FabLab, con pinout consolidado y validación eléctrica completa.
- **Carcasa protectora**: cerramiento de dos piezas en PLA con *lug* para correa estándar, ventana óptica alineada al MAX30102 y dos pernos de acero inoxidable AISI 304 en la contracara para el circuito ECG.

- **Aplicación móvil Flutter** con dashboard biométrico, historial persistente en Hive [13], captura de ventanas IMU/ECG para *ground truth* y sincronización con Firebase Firestore bajo autenticación.
- **Herramientas de validación offline** en `tools/` para entrenamiento, generación de matrices de confusión, *replay* del algoritmo de pasos y cálculo Pan-Tompkins sobre trazas reales.

1. Descripción del proyecto

1.1. Contexto y motivación

Chile presenta uno de los perfiles más adversos de América Latina en cuanto a sedentarismo y sobrepeso. Según los resultados de la Encuesta Nacional de Actividad Física y Deporte [14], sólo el 49,7 % de los hombres y el 40,3 % de las mujeres mayores de 18 años cumplen con los niveles recomendados de actividad física. La Encuesta Nacional de Salud del MINSAL [15] y los reportes de UC Christus [16] confirman que más del 42 % de la población adulta presenta sobrepeso u obesidad, ubicando al país en el primer lugar regional. En este escenario, las herramientas de auto-monitorización biométrica de uso continuo cumplen un rol relevante en políticas de prevención cardiovascular y metabólica, especialmente si son accesibles económicamente y respetuosas con la salud mental del usuario.

Los relojes comerciales dominantes en el mercado chileno (Apple Watch SE [17], Samsung Galaxy Watch [9], Garmin Venu [18]) integran una excelente cadena biométrica pero adolecen de dos limitaciones importantes para el uso masivo y personal: primero, su costo (entre \$150.000 y \$300.000 CLP) queda fuera del alcance de amplios sectores de la población que más se beneficiarían de un auto-monitoreo cotidiano; segundo, su modelo de negocio favorece el consumo de notificaciones sociales y aplicaciones que introducen carga cognitiva sostenida, un fenómeno estudiado por Kushlev et al. [19] y por Pielot et al. [20] que se asocia con déficits atencionales y estrés crónico. El proyecto SupaClock responde a este diagnóstico proponiendo una plataforma de bajo costo, con diseño filosóficamente centrado en la biometría y explícitamente austera en distracciones, cuyos datos son propiedad del usuario y no dependen de *clouds* de terceros ni de suscripciones periódicas.

En paralelo, la incorporación de *machine learning in edge* representa una oportunidad técnica y ética distintiva. Ejecutar la clasificación de actividad física directamente en el reloj significa que los datos crudos de la unidad inercial nunca abandonan el dispositivo, y que el sistema puede operar completamente sin conexión a Internet. Wearables comerciales validados clínicamente [21] han demostrado que las decisiones biomédicas pueden apoyarse en dispositivos personales, siempre que se mantengan transparentes sus limitaciones y se privilegien arquitecturas interpretables por sobre modelos opacos.

1.2. Alcance del proyecto

SupaClock es un *wearable* biométrico personal de segunda generación que integra sensores de contacto (temperatura, PPG, ECG monoderivación) e inerciales (acelerómetro y giroscopio), procesamiento local con clasificación *on-device* de actividad física mediante una CNN 1D cuantizada, una interfaz táctil circular basada en LVGL, comunicación Bluetooth Low Energy con una aplicación móvil compañera y sincronización selectiva de datos hacia un *backend* Firebase. El sistema está pensado para monitoreo cotidiano de usuarios adultos con interés en su bienestar físico, sesiones puntuales de ejercicio, y para el registro de electrocardiogramas de tamizaje realizados en reposo con las dos manos sobre los pernos posteriores del dispositivo.

Es igualmente relevante enunciar aquello que el proyecto *no* pretende ser. SupaClock no está homologado como dispositivo médico y sus mediciones no constituyen diagnóstico clínico; el disclaimer correspondiente se muestra en la pantalla de ECG del reloj y en la interfaz de la aplicación. Tampoco compete en catálogo de aplicaciones sociales, notificaciones o entretenimiento con relojes comerciales: su premisa explícita es priorizar la sencillez de uso y la ausencia de distracciones. Finalmente, no se busca sustituir el rol de las evaluaciones profesionales, sino habilitar un canal accesible para que el usuario adquiera consciencia de sus propias trazas biométricas cotidianas.

2. Requerimientos y especificaciones

Esta sección enuncia los requerimientos del sistema en tres capas —funcionales, no funcionales y regulatorios— traducidos a especificaciones cuantitativas y respaldados por las normas o *datasheets* correspondientes. Los cumplimientos observados sobre el prototipo cerrado se discuten en §3.2.

2.1. Requerimientos funcionales

Los requerimientos funcionales enumeran las cadenas de medición y las interacciones esperadas por el usuario final. La Tabla 1 consolida el listado.

Cuadro 1: Requerimientos funcionales de SupaClock y especificaciones cuantitativas asociadas.

Requerimiento	Especificación cuantitativa	Fuente / norma
Temperatura de piel	Medición continua con error absoluto $\leq 0,5^\circ\text{C}$ entre 30°C y 40°C . Resolución nativa $0,00390625^\circ\text{C}$.	MAX30205 [22], IEEE 11073-10406 [23]
HR y SpO ₂ ópticos	Frecuencia cardíaca en el rango 40–180 bpm con error medio $\leq 3\%$ y saturación de oxígeno en 85–100 % con error $\leq 3\%$. Muestreo 100 Hz RED+IR.	MAX30102 [24], [21]
ECG monoderivación	Señal AD8232 acondicionada con ancho de banda 0,5–40 Hz, ADC a 500 Hz y detección de picos R por Pan-Tompkins. Ventana típica de 30–60 s.	AD8232 [25], [12, 23]
Actividad física	Clasificación continua entre reposo, caminata, trote y escaleras, cada 2 s, con exactitud global $\geq 90\%$ sobre el conjunto de validación.	CNN 1D on-device [26, 27, 8]
Conteo de pasos	Detección por análisis espectral de la magnitud del acelerómetro con banda de cadencia 1,0–2,5 Hz e histéresis temporal. Error $\leq 5\%$ en trayectorias de 500 pasos.	BMI160 [28], ESP-DSP [10]
Interfaz de usuario	Pantalla <i>watchface</i> + tiles biométricos + panel rápido + <i>drawer</i> , con navegación por gestos táctiles y botón único.	GC9A01 [29], CST816S [30], LVGL [31]
Sincronización con <i>app</i>	Vinculación BLE una vez, <i>dashboard</i> en vivo, historial persistente en la aplicación y almacenamiento por usuario en Firestore.	BLE 5.3 [32], Firebase [6, 4]

2.2. Requerimientos no funcionales

Los requerimientos no funcionales acotan la ergonomía física del dispositivo, la latencia de la comunicación y el envolvente energético. La Tabla 2 presenta el listado.

Cuadro 2: Requerimientos no funcionales y métricas objetivo.

Requerimiento	Especificación cuantitativa	Fuente / referencia
Autonomía	Uso mixto (pantalla + BLE + HAR periódico) ≥ 6 h continuas antes de la protección UVP. Deep sleep con consumo $\leq 30 \mu A$.	MAX17048 [33], [34]
Tamaño cerrado	Volumen envolvente $\leq 90 \text{ cm}^3$ pensado en confort ergonómico de muñeca.	Ergonomía <i>wrist-worn</i>
Peso	Unidad cerrada con batería ≤ 150 g incluyendo carcasa PLA.	Ergonomía <i>wrist-worn</i>
Latencia BLE	Mediana ≤ 100 ms para paquetes de telemetría (13 B/s) y <i>chunks</i> ECG (20 B).	BLE 5.3 [32], NimBLE [11]
Aislamiento eléctrico al usuario	Impedancia de entrada $> 10 \text{ M}\Omega$ y corriente de fuga DC $< 10 \mu A$ en el subsistema ECG.	IEC 60601-1 tipo BF [35]
Consumo de datos móviles	≤ 5 MB/día en modo típico (dashboard + una sesión ECG de 30 s).	Arquitectura <i>edge</i> -céntrica

2.3. Requerimientos éticos y regulatorios

SupaClock se declara explícitamente como dispositivo no médico: la interfaz del reloj y la aplicación móvil muestran, en cada vista de ECG y de saturación de oxígeno, un mensaje que aclara que las mediciones no constituyen diagnóstico clínico. Los componentes seleccionados cumplen la Directiva RoHS-2 [36] en tanto encapsulados libres de plomo, y la celda LiPo integrada respeta los criterios de seguridad de la norma IEC 62133-2 [37] (protección de sobrecarga, sobre-descarga, cortocircuito y sobret temperatura, provista por el DW01A [38] interno de la propia celda). En materia de privacidad, la aplicación móvil implementa autenticación Google mediante Firebase Authentication [6] y las reglas de Cloud Firestore restringen la lectura y escritura de documentos al identificador del usuario propietario (`request.auth.uid == userId`), en concordancia con el espíritu de la Ley 19.628 chilena [39] y del Reglamento General de Protección de Datos europeo [40]. No se transmiten datos crudos de la IMU al *cloud*: la clasificación de actividad física ocurre por completo en el reloj, y sólo la etiqueta consolidada se sincroniza con la aplicación.


3. Prototipo final

3.1. Descripción del prototipo y experiencia de uso

El prototipo cerrado de SupaClock se percibe como un reloj de muñeca de tamaño compacto, con una envolvente rectangular redondeada de $17\text{ mm} \times 74\text{ mm} \times 93\text{ mm}$ y una masa neta de 115 g medida sobre balanza de laboratorio incluyendo la carcasa impresa en PLA, la PCB Carrier v4 poblada, el módulo XIAO ESP32-S3, la batería LiPo de 300 mAh, el LCD circular, la tornillería M3 y los pernos posteriores de acero inoxidable AISI 304. La cara frontal aloja una pantalla táctil circular GC9A01 de 1,28" y 240×240 píxeles [29], gestionada por LVGL 8.4 [31] sobre *framebuffer* en PSRAM. La cara posterior expone la ventana óptica alineada al MAX30102 y los dos pernos AISI 304 en los que el usuario coloca las yemas de la mano opuesta para completar el circuito ECG monoderivación. Una correa estándar de 20 mm se ancla a dos *lugs* laterales impresos como parte de la propia carcasa. La Fig. ?? y las imágenes complementarias de la Fig. 1 ilustran la unidad cerrada.



(a) Vista frontal cerrada con pantalla apagada.




(b) Vista lateral y detalle de *lugs* para correa.


Figura 1: Prototipo cerrado en detalle. La carcasa se atornilla con cuatro pernos M3 y expone las aberturas alineadas para los sensores biométricos.

El usuario enciende el dispositivo mediante una pulsación prolongada de 3 s sobre el botón lateral único. Una vez encendido, la interfaz muestra un *watchface* minimalista con la hora, un icono dinámico que refleja la actividad clasificada por el modelo HAR y una barra de batería entregada por el MAX17048 [33]. Deslizando lateralmente el dedo el usuario recorre los *tiles* biométricos —frecuencia cardíaca, saturación de oxígeno, temperatura, actividad HAR y pasos— cada uno con su propia visualización temática. Al deslizar hacia abajo desde el borde superior aparece un panel rápido con brillo, silencio de vibración y toggle de deep sleep; al deslizar hacia arriba aparece un *drawer* inferior con la sesión de ECG puntual y la ventana de calibración. Todo el ciclo de navegación se diseñó para que en menos de tres gestos el usuario acceda a cualquier métrica biométrica, siguiendo la filosofía austera enunciada en §1.


La aplicación móvil compañera es una *app* Flutter [4] disponible en Android que se vincula al reloj vía Bluetooth Low Energy usando `flutter_blue_plus` [5]. Tras un *login* con cuenta Google integrado con Firebase Authentication [6], la aplicación descubre el servicio GATT custom `0xFF00` publicado por el reloj y se suscribe a las cuatro características: telemetría biométrica agregada, *stream* continuo del IMU, *chunks* de ECG y comandos de configuración. El *dashboard* muestra en vivo la frecuencia cardíaca, la temperatura, la saturación de oxígeno, la actividad HAR clasificada por el reloj y el contador acumulado de pasos, con historial paginado por día almacenado localmente en Hive [13] y respaldado en Cloud Firestore [41]. La Fig. 2 muestra las tres pantallas principales de la aplicación móvil.



(a) *Dashboard* biométrico.



(b) Captura de IMU y *ground truth*.



(c) Registro y sesiones.

Figura 2: Vistas principales de la aplicación móvil Flutter de SupaClock.

De forma silenciosa en segundo plano, el firmware ejecuta una serie de tareas concurrentes bajo FreeRTOS: la tarea `imu_task` drena el FIFO del BMI160 [28] a 50 Hz, alimenta el *ring buffer* del HAR con cada muestra y notifica a la tarea de inferencia `har_task` cuando se acumula una ventana completa; esta corre pinneada en el núcleo 1 del ESP32-S3, invoca al intérprete TFLite Micro y actualiza la etiqueta de actividad cada 2s. Simultáneamente, `ppg_task` maneja el MAX30102 para el cálculo de HR/SpO₂, `ecg_task` orquesta la captura ADC/DMA del AD8232 cuando el usuario inicia una sesión ECG, `ble_task` atiende el *stack* NimBLE y `lvgl_task` refresca la UI. Cuando el usuario pulsa el botón lateral por 3s, el firmware apaga los sensores mediante los comandos de bajo consumo del BMI160/MAX30102/MAX30205 y entra a *deep sleep*, dejando activo un despertador *RTC-GPIO* en el mismo botón. Este ciclo permite reencender el dispositivo en menos de 2s.

El caso de uso pensado combina cuatro escenarios: monitoreo cotidiano continuo, sesiones deportivas de mediana duración, chequeos puntuales de ECG con la persona sentada en reposo y monitoreo nocturno de SpO₂ y actividad. En todos los casos el reloj funciona sin dependencia del teléfono, y éste último se emplea sólo para revisar historiales, exportar sesiones y respaldar en el *backend* bajo autenticación del propietario.

3.2. Análisis de cumplimiento de especificaciones

La Tabla 3 sintetiza el cumplimiento de las especificaciones enunciadas en la sección 2, cruzando cada requerimiento con el método de medición empleado, el resultado obtenido sobre el prototipo cerrado y una marca binaria de cumplimiento.

Cuadro 3: Análisis de cumplimiento de especificaciones sobre el prototipo cerrado. Los detalles de cada medición se documentan en §5.

Requerimiento	Especificación	Método de medición	Resultado	Cumple
HR	Error $\leq 3\%$ vs referencia	Comparación con Galaxy Watch 4 [9] sobre el mismo usuario, sesión de 5 min	Error medio 2 %	✓
SpO ₂	Error $\leq 3\%$ vs referencia	Oxímetro Galaxy Watch 4 [9] sobre el mismo usuario	Error medio 2 %	✓
Temperatura piel	Error $\leq 0,5^{\circ}\text{C}$ @ 30–40 °C	Termómetro digital de contacto en muñeca	33,1 °C SupaClock vs 33,3 °C referencia ($\Delta = 0,2^{\circ}\text{C}$)	✓
ECG	Onda visualmente similar; HRV robusta	Comparación cualitativa vs Galaxy Watch 4 y análisis Pan-Tompkins offline	Onda R detectada; HR ~ 64 bpm; HRV(SDNN) ~ 158 ms; variación 5 % vs referencia	✓
Pasos	Error $\leq 5\%$ en 500 pasos	Conteo manual + <i>replay</i> offline del algoritmo FFT sobre traza de 384 pasos	Error 2 % (in-situ); 379 vs 384 (−1,3 %) en <i>replay</i>	✓
HAR	Exactitud global $\geq 90\%$	Validación 80/20 sobre dataset propio con <code>tools/har_confusion.py</code>	Exactitud 95,0 %; recall stairs 55 % discutido	✓
Autonomía	≥ 6 h uso mixto	Curva de descarga instrumentada por MAX17048	~ 10 h hasta corte al 20 % SoC	✓
Tamaño cerrado	$\leq 90\text{ cm}^3$ envoltente	Medición directa con pie de metro sobre la unidad ensamblada	$17 \times 74 \times 93\text{ mm} = 117\text{ cm}^3$ envoltente	parcial
Peso	$\leq 150\text{ g}$	Balanza de precisión	115 g cerrado	✓
Latencia BLE	Mediana $\leq 100\text{ ms}$	<i>nRF Connect</i> con captura de <i>chunks</i> de ECG	Mediana 38 ms; p90 67 ms; p99 144 ms	✓
Aislamiento ECG	$R_{\text{in}} > 10\text{ M}\Omega$, $I_{\text{DC}} < 10\text{ }\mu\text{A}$	Datasheet AD8232 + revisión de topología	$R_{\text{in}} \sim 10^{12}\text{ }\Omega$; $I_{\text{DC}} \sim 100\text{ pA}$	✓
Consumo móvil	$\leq 5\text{ MB/día}$ típico	Payload agregado + una sesión ECG de 30 s ($\sim 30\text{ KB}$ comprimido)	$< 1\text{ MB/día}$ típico	✓

De las 12 especificaciones auditadas, 11 se cumplen dentro de la tolerancia planteada. El único incumplimiento formal es el volumen envoltente: la unidad cerrada mide 117 cm^3 , ligeramente por sobre la meta interna de 90 cm^3 . La medición considera el paralelepípedo mínimo que contiene la unidad; en la práctica, el volumen efectivamente ocupado por la carcasa es sustancialmente menor debido a la geometría redondeada, y el usuario percibe el reloj como delgado (17 mm de perfil). Esta desviación se declara honestamente y se propone en §7 como una línea de trabajo futuro (miniaturización de la Carrier a doble cara con condensadores SMD 0402 y traslado del cargador a MCP73831/2 [42]).

3.3. Lista de materiales y análisis de costo

La Tabla 4 presenta la lista de materiales consolidado de la unidad final, incluyendo componentes electrónicos, mecánicos y de ensamblaje. Los precios se cotizaron en pesos chilenos considerando proveedores locales y minorista para pequeños volúmenes (LCSC, DigiKey CL, MakerElectronico, FabLab).

Cuadro 4: Lista de materiales del prototipo final SupaClock. Precios en CLP a julio de 2026.

Componente	Cant.	Proveedor	Unit. (CLP)	Total (CLP)
Seeed XIAO ESP32-S3 (8 MB PSRAM, 8 MB Flash)	1	MakerElectronico	14.900	14.900
LCD GC9A01 1,28" con <i>touch</i> CST816S	1	AliExpress	7.500	7.500
BMI160 IMU 6-DoF (módulo)	1	LCSC	3.100	3.100
MAX30102 PPG (módulo)	1	LCSC	2.400	2.400
MAX30205 sensor de temperatura (módulo)	1	LCSC	3.200	3.200
AD8232 front-end ECG (módulo)	1	MakerElectronico	6.800	6.800
MAX17048 <i>fuel gauge</i> (módulo)	1	LCSC	2.700	2.700
Batería LiPo 300mAh con PCM DW01A	1	LCSC	3.400	3.400
Pernos AISI 304 (contactos ECG)	2	FabLab	200	400
PCB Carrier v4 (fresado LPKF)	1	FabLab	4.500	4.500
Componentes pasivos (Rs, Cs, Ls, headers)	1	LCSC	2.500	2.500
Carcasa PLA impresa (piezas superior + inferior)	1	FabLab	3.500	3.500
Correa estilo silicona 20 mm	1	AliExpress	2.900	2.900
Tornillería M3 (cabeza avellanada + tuercas embutidas)	8	FabLab	100	800
Cable USB-C 1 m	1	MakerElectronico	1.500	1.500
TOTAL PROTOTIPO				60.100

Adicionalmente, los gastos reales incurridos durante la etapa de desarrollo, pruebas y puesta en marcha del proyecto se detallan en la Tabla 5. Esta tabla consolida el desglose de la lista de compras del proyecto (obtenido de las adquisiciones registradas de sensores y materiales base) sumado a los gastos adicionales por concepto de consumibles e imprevistos (componentes e instrumental de repuesto adquiridos debido a fallas, caídas o quemaduras durante las pruebas de bring-up).

Cuadro 5: Gastos de desarrollo, repuestos e imprevistos acumulados durante el proyecto SupaClock. Precios en CLP.

Componente / Descripción	Cant.	Origen / Motivo	Unit. (CLP)	Total (CLP)
Adquisiciones base (Desglose de lista de compras)				
Módulo inercial BMI160	1	AliExpress (Great IT)	2.527	2.527
Módulo PPG MAX30102	2	AliExpress (Great IT)	1.547	3.094
Placa de desarrollo ESP32-S3	1	AliExpress (QJY Dept)	8.311	8.311
Pantalla LCD GC9A01 con touch	1	AliExpress (HelloWiki)	2.246	2.246
Kit de conectores XH2.54	1	AliExpress (Canrick)	2.514	2.514
Pantalla LCD TFT 1,3"	1	AliExpress (Jin Rong)	2.559	2.559
Módulo AD8232 ECG	1	AliExpress (YueLong)	5.718	5.718
Pantalla LCD TFT 1,28" (GC9A01)	1	AliExpress (Jin Rong)	2.114	2.114
Sensor de temperatura MAX30205	2	AliExpress (Shop1102)	1.402	2.803
Tornillería y pernos M3	1	AliExpress (HILIFE)	2.909	2.909
Batería LiPo 300 mAh (901515)	1	AliExpress (Eclardyn)	3.170	3.170
Placa de desarrollo ESP32-C3	1	AliExpress (HNB DIY)	2.235	2.235
Módulo de carga de baterías	1	AliExpress (AILEH-KUO)	1.543	1.543
Herramientas de fresado LPKF	1	AliExpress (CPU-Chip)	12.238	12.238
Joystick de reemplazo 3D	1	AliExpress (DATA FROG)	2.627	2.627
Gastos adicionales e imprevistos de desarrollo				
Placa de desarrollo ESP32-S3 inicial	2	Adquisición inicial	10.500	21.000
Filamento PLA (carcasa 3D)	1	Impresora 3D propia	10.000	10.000
Módulo AD8232 ECG (re- puesto)	1	Reemplazo por compo- nente quemado	9.990	9.990
Pantalla touch (repuesto)	1	Caída / flex cortado de pantalla original	10.000	10.000
Placa de desarrollo ESP32-S3 (repuesto)	1	Reemplazo por compo- nentes quemados	18.990	18.990
Placas PCB Carrier v4 y PCB adaptador	10	5 Carrier + 5 adapta- dores (no utilizados)	1.000	10.000
TOTAL GASTOS DE DESARROLLO				136.588

El costo total del prototipo asciende a \$60,100 CLP, cifra sustancialmente inferior a la de las alternativas comerciales de referencia: Apple Watch SE (~\$250,000 CLP) [17], Samsung Galaxy Watch FE (~\$160,000 CLP) [9] y Garmin Venu de acceso (~\$200,000 CLP) [18]. Comparado con bandas de bajo costo tipo Mi Band (~\$30,000 CLP), SupaClock se posiciona como una plataforma de costo medio pero con una cadena biométrica más completa (incluye ECG monoderivación y temperatura de contacto), procesamiento ML on-device y arquitectura abierta con datos propios. El desglose porcentual del costo se distribuye aproximadamente en 40 % sensores biométricos (BMI160 + MAX30102 + MAX30205 + AD8232), 25 % MCU + display + *touch*, 15 % mecánica y ensamblaje, 10 % subsistema de energía (batería + *fuel gauge*) y 10 % restos (correa, cables, pasivos). El proyecto es además susceptible de reducirse a menos de \$45,000 CLP en producción de 50 unidades mediante PCB SMD de 4 capas en JLCPCB y compras al por mayor de los sensores.

4. Diagrama de bloques de bajo nivel

4.1. Diagrama actualizado al estado final

La Fig. 3 muestra el diagrama de bloques de bajo nivel de SupaClock en su estado final. El microcontrolador Seeed XIAO ESP32-S3 (módulo SMD con 8 MB de PSRAM externa y 8 MB de Flash) actúa como núcleo central del sistema, ejecutando FreeRTOS con múltiples tareas concurrentes distribuidas entre sus dos núcleos Xtensa LX7 y hospedando el intérprete TensorFlow Lite Micro para la clasificación HAR. A la derecha del MCU se agrupan los cuatro sensores biométricos: el MAX30205 en la dirección I²C 0x48 entrega temperatura de piel; el BMI160 en 0x68 entrega acelerómetro y giroscopio de 6 grados de libertad a 50 Hz configurables mediante su FIFO interno; el MAX30102 en 0x57 entrega intensidad óptica RED e IR a 100 Hz para el cálculo de HR y SpO₂; y el AD8232 acondiciona la señal ECG diferencial hacia el canal ADC1_CH0 (GPIO1), muestreado a 500 Hz mediante el motor ADC continuo con DMA del ESP-IDF. A la izquierda se despliega la subsección de interfaz local (LCD GC9A01, *touch* CST816S) y la subsección de energía (batería LiPo 300 mAh con protección DW01A integrada, cargador SGM40567 CC/CV, buck SGM6029 al rail de 3,3 V, *fuel gauge* MAX17048 monitoreado por I²C y entrada USB-C). En la parte inferior se representa el ecosistema: la pila NimBLE publica un servicio GATT custom 0xFF00 con cuatro características, la aplicación móvil Flutter actúa como *gateway* y sincroniza selectivamente con Firebase Firestore, el modelo HAR CNN 1D corre *on-device* en el núcleo 1 del ESP32-S3, la PCB Carrier v4 fresada en el FabLab integra físicamente todos los subsistemas, y el algoritmo Pan-Tompkins se ejecuta *app-side* sobre las trazas ECG que envía el reloj. Los buses están codificados por color (azul para I²C a 400 kHz, violeta para SPI a 40 MHz, naranja para ADC/DMA, azul discontinuo para BLE) y las flechas rojas representan la cadena de potencia.




Figura 3: Diagrama de bloques de bajo nivel de la unidad final SupaClock. El XIAO ESP32-S3 concentra los buses I²C, SPI y ADC/DMA, ejecuta FreeRTOS con la tarea de HAR pinneada en el núcleo 1, y expone un servicio BLE custom hacia la aplicación móvil que sincroniza con Firebase Firestore. La cadena de energía va desde la entrada USB-C o la batería LiPo, pasa por el cargador SGM40567, el buck SGM6029 al rail de 3,3V y es monitoreada por el *fuel gauge* MAX17048.

4.2. Especificaciones por bloque e interconexiones

La Tabla 6 consolida las especificaciones y la asignación precisa de pines de cada bloque, junto con el ancho de banda y el modo de comunicación empleado. Las asignaciones de GPIO reflejan el archivo `include/supaclock_pinmap.h` del firmware, cuyo extracto se incluye en el Anexo A.1.

Cuadro 6: Especificaciones e interconexiones detalladas por bloque de la unidad final.

Bloque	Pin/Recurso	Bus / velocidad	Rol y observaciones
XIAO ESP32-S3	Dual-core LX7 @ 240 MHz	—	8 MB PSRAM (arena TFLite), 8 MB Flash, PSRAM en modo Octal, USB CDC nativo para logging. [2, 3]
I ² C compartido	SDA=GPIO5, SCL=GPIO6	I ² C @ 400 kHz	Cuatro esclavos: BMI160 (0x68), MAX30102 (0x57), MAX30205 (0x48), MAX17048 (0x36).
SPI LCD	MOSI=GPIO9, SCK=GPIO7, CS=GPIO44, DC=GPIO4	SPI @ 40 MHz	GC9A01 240 × 240; <i>framebuffer</i> en PSRAM, refresco por DMA. [29, 31]
Touch capacitivo	INT=GPIO2, RST=GPIO21	I ² C @ 400 kHz (mismo bus)	CST816S; interrupción hacia GPIO2 y <i>reset</i> manual vía GPIO21. [30]
ADC/DMA para ECG	ADC1_CH0 (GPIO1)	500 Hz, buffer 1024 muestras	Motor ADC continuo del ESP-IDF; la señal se convierte y drena a <i>ecg_task</i> para enviár por BLE en <i>chunks</i> de 20 B. [25]
Botón lateral	SEL=GPIO8	GPIO + RTC-GPIO	Encendido, deep sleep, <i>wake</i> .
BLE NimBLE	—	LE 1M PHY, MTU 247	Servicio custom 0xFF00 con 4 características (telemetría, IMU stream, ECG stream, comandos). [32, 11]
Cadena de energía	USB-C, SGM40567 CC/CV, SGM6029 buck, MAX17048	—	Batería LiPo 300 mAh con DW01A integrado; rail 3,3 V regulado; <i>fuel gauge</i> por I ² C. [43, 44, 38, 33]
Deep sleep	Wake por botón RTC-GPIO	—	Consumo objetivo $\sim 15 \mu\text{A}$ con MAX30102, MAX30205 y BMI160 en modo suspendido. [34]

5. Implementación y resultados

Esta sección presenta la implementación de cada subsistema del sistema en su estado final. La estructura sigue el orden lógico de flujo de datos: primero se describe la arquitectura de firmware que coordina el conjunto, luego la adquisición de las señales biométricas por sensor, luego el procesamiento local en el reloj y en la aplicación móvil, luego el modelo de *machine learning on-device*, luego el ecosistema móvil y de *cloud*, y finalmente la mecánica, la energía y la validación cuantitativa consolidada. Cada subsección presenta la implementación real y la respalda con figuras y mediciones cuando el resultado es cuantitativo.

5.1. Arquitectura de firmware y particionamiento de tareas

El firmware de SupaClock se estructura en la biblioteca `lib/supaclock_app/`, que expone una API pequeña consumida por `src/main.c`: éste último inicializa los buses, monta el sistema de archivos, arranca los subsistemas biométricos y crea el *event loop* de la interfaz gráfica. Los subsistemas individuales viven en bibliotecas separadas, lo que permite recompilar aisladamente y montar bancos de prueba automáticos por módulo. La compilación está orquestada por PlatformIO con ESP-IDF 5.5.3 y decenas de entornos `sdkconfig.test_*`, que activan/desactivan módulos para los tests de bring-up.

Sobre FreeRTOS [45], la carga se reparte deliberadamente entre los dos núcleos del ESP32-S3 para evitar el bloqueo mutuo entre la inferencia HAR y las tareas de radio/UI. La Fig. 4 resume la distribución. La tarea `imu_task` (núcleo 0, prioridad 5) drena el FIFO del BMI160 cada 20 ms y, por cada muestra, invoca `har_cnn1d_push_sample()` que la escribe en el *ring buffer* del HAR; cuando se acumulan `HAR_HOP_SIZE` muestras nuevas, se notifica a la tarea `har_task`, que corre pinneada en el núcleo 1 con prioridad 4 y ejecuta la inferencia sobre la ventana completa. Este diseño logra dos objetivos: hay un único lector I²C del BMI160 (evitando contención de bus y *overflow* del FIFO), y la inferencia pesada nunca bloquea el *advertising* BLE ni el refresco de LVGL, gestionados en el núcleo 0. Las tareas restantes (`ppg_task`, `ecg_task`, `ble_task`, `lvgl_task`) también corren en el núcleo 0 con prioridades escalonadas según su criticidad temporal.




Figura 4: Particionamiento FreeRTOS del firmware final. Las tareas de sensado y UI viven en el núcleo 0; la tarea de inferencia HAR está pinneada en el núcleo 1, alimentada por las muestras que `imu_task` empuja a su *ring buffer*. La arena TFLite reside en PSRAM.

El extracto del `pinmap` en el Anexo A.1 muestra la centralización de asignaciones de GPIO, evitando la dispersión de constantes mágicas en el código. Cada subsistema consume las macros correspondientes al

inicializarse.

5.2. Sensores y adquisición de señales

La adquisición biométrica se apoya en cuatro cadenas de sensor con drivers propios optimizados para el consumo y la concurrencia.

BMI160 — unidad inercial de 6 grados de libertad

El BMI160 [28] entrega aceleración y giroscopio con configuración $\pm 4g$ y $\pm 500^\circ/s$. El driver interno (`lib/bmi160_driver/`) configura el sensor a 50 Hz con FIFO habilitado, lo que permite drenar por I²C bloques de 30–40 tramas de golpe sin perder muestras aunque `imu_task` sufra jitter de decenas de milisegundos. Una decisión deliberada del proyecto es **no** usar el contador de pasos por *hardware* del BMI160: en su lugar, un algoritmo basado en FFT sobre el mismo *stream* unificado calcula pasos y actividad HAR (memoria de proyecto). Esta unificación evita perturbaciones al momento de suspender/reactivar el sensor, y permite compartir sus muestras entre módulos consumidores.

MAX30102 — fotopletismografía RED e IR

El MAX30102 [24] se configura en modo dual-*LED* a 100 Hz con ancho de pulso 411 μs y *sample average* de 4. El driver (`lib/max30102_driver/`) lee la FIFO por I²C, aplica un filtro pasabanda de latido y estima la frecuencia cardíaca por autocorrelación. La saturación de oxígeno se obtiene por la razón clásica $R = (AC_{RED}/DC_{RED})/(AC_{IR}/DC_{IR})$ interpolada por la curva de calibración estándar. En *deep sleep* el módulo se apaga escribiendo 0x41=0x80, con consumo residual $< 1 \mu A$.

MAX30205 — temperatura corporal de contacto

El MAX30205 [22] tiene una resolución nativa de 0,00390625 °C y precisión tipificada de $\pm 0,1^\circ C$ entre 37,0 y 39,0 °C. El driver (`lib/max30205_driver/`) opera en modo continuo, muestreando cada 2 s y suministrando la lectura al *tile* de temperatura y al *payload* BLE. En *deep sleep* el sensor se pone en modo apagado por el bit 0 de su registro de configuración.

AD8232 — electrocardiograma monoderivación

El AD8232 [25] recibe las señales de los pernos AISI 304 en la contracara del reloj (mano opuesta del usuario) y su salida analógica llega al canal ADC1_CH0 (GPIO1) del ESP32-S3. La captura se orquesta con el motor *ADC continuous* del ESP-IDF, que rellena un *ring buffer* de 1024 muestras a 500 Hz mediante DMA, sin ocupar CPU. El driver (`lib/ad8232_driver/`) expone una API asincrónica que abastece a `ecg_task`, la cual empaqueta los *chunks* de 20 B y los publica por la característica GATT correspondiente cuando el usuario inicia una sesión ECG desde la aplicación móvil o desde la propia pantalla del reloj.

5.3. Procesamiento local: Pan-Tompkins y pasos por FFT

Pan-Tompkins app-side

Aunque SupaClock dispone del ancho de banda y la memoria suficientes para ejecutar Pan-Tompkins [12] en el propio reloj, se decidió hacerlo del lado de la aplicación Flutter por dos razones pragmáticas:

primero, permite iterar rápidamente en Python el algoritmo y correlacionar visualmente contra la señal cruda de la que dispone el usuario en la aplicación; segundo, deja el reloj enfocado a la adquisición y a la transmisión BLE, respetando el presupuesto de energía y el aislamiento entre *tasks*. El pipeline replica fielmente los pasos clásicos: filtro pasabanda 0,5–40 Hz [23], derivada de primer orden, cuadrado punto a punto, integración por ventana móvil de 150 ms y umbralización adaptativa; el refinamiento local del pico R se hace sobre la señal filtrada. La Fig. 5 muestra el resultado sobre una captura real de 37 s en reposo del usuario Pablo Uribe: se detectan 39 picos R, con una frecuencia cardíaca estimada de ~ 64 bpm y una variabilidad HRV(SDNN) ~ 158 ms, en el rango fisiológico normal.




Figura 5: Señal ECG SupaClock (AD8232 $\rightarrow$ ESP32-S3, ~ 500 Hz) con detección de picos R por el pipeline Pan-Tompkins app-side. El panel superior muestra la señal cruda del ADC, el inferior la señal filtrada 0,5–40 Hz con los 39 picos detectados en 37 s marcados en rojo. HR estimada ~ 64 bpm; HRV(SDNN) ~ 158 ms.

Pasos por FFT en el reloj

El algoritmo de pasos vive en `lib/step_algorithm/step_algorithm.c` y opera sobre la magnitud $|\vec{a}|$ del vector de aceleración. Cada 128 muestras a 50 Hz (ventana de 2,56 s) se aplica una FFT compleja de 128 puntos vía ESP-DSP [10], aprovechando la aceleración por SIMD del ESP32-S3. La banda de interés 1,0–2,5 Hz cubre las cadencias humanas típicas de caminata y trote; el pico dominante se acepta como candidato válido sólo si su energía supera un umbral empírico calibrado y si el intervalo entre pasos sucesivos respeta una histéresis temporal mínima (evita rebotes cuando el reloj se mueve pasivamente en la muñeca). La Fig. 6 muestra el resultado del algoritmo sobre una traza real de 384 pasos: el conteo obtenido es 379, con un error relativo del $-1,3$ %.




Figura 6: Detección FFT de pasos sobre una traza real. La ventana Hann de 128 muestras a 50 Hz permite estimar la cadencia dominante en la banda 1,0–2,5 Hz; el algoritmo cuenta 379 pasos contra 384 manuales (−1,3 % de error).

5.4. Machine Learning on-device: HAR CNN 1D

El clasificador de actividad física es el diferenciador técnico central del proyecto. Corre **a bordo del reloj**, no en la aplicación móvil ni en el *backend*. Esta sección describe el dataset propio, la arquitectura neuronal, el proceso de entrenamiento y cuantización, el *runtime* TensorFlow Lite Micro sobre el ESP32-S3 y las métricas obtenidas.

Dataset y *ground truth*

El dataset final agrupa más de 30 minutos de captura propia obtenida con el propio reloj a 50 Hz. La aplicación móvil Flutter incluye un flujo específico para grabar una sesión etiquetada: el usuario selecciona la clase (*rest*, *walk*, *run* o *stairs*), inicia la captura y el reloj transmite el *stream* IMU crudo por BLE mientras la aplicación lo comprime en *.csv.gz* en el sistema de archivos del teléfono. Los archivos resultantes viven en el directorio *data_ml/* del repositorio y suman 50 + sesiones: 4 clases × diversidad de gestos (por ejemplo, escaleras hacia arriba y hacia abajo, caminata plana, caminata cuesta abajo, trote sostenido).

El pipeline de preparación (*tools/train_har_cnn.py*) filtra tramas corruptas (valores centinela −1, −32768), decima a 50 Hz aquellos archivos legado capturados a 100 Hz y aplica *rotation augmentation* 3D con rotaciones *yaw/pitch/roll* ×2, obteniendo tres variantes por ventana. Además, un *bias* de −15 % sobre la clase *stairs* compensa su sub-representación relativa en el dataset final.

Arquitectura CNN 1D

La red es secuencial (sin conexiones residuales, tras probar y descartar una variante ResNet que agotaba la arena TFLite en tiempo de ejecución) y sigue el patrón *estimador local* → *captura temporal* → *clasificación global*. La Fig. 7 muestra el diagrama de bloques con las formas tensoriales de cada etapa:




Figura 7: Arquitectura CNN 1D del clasificador HAR de SupaClock. Cuatro bloques conceptuales: extracción local (Conv1D 32 + Pool), temporal medio (Conv1D 64 + Pool), alto nivel (Conv1D 128 + GAP) y clasificador denso (Dense 64 + Softmax de 4 clases). Total: $\sim 44k$ parámetros.

En pseudo-código Keras:

```

1 model = models.Sequential([
2     layers.InputLayer(input_shape=(WINDOW_SIZE, NUM_CHANNELS)),
3     layers.Conv1D(filters=32, kernel_size=5, activation='relu', padding='same'),
4     layers.MaxPooling1D(pool_size=2),
5     layers.Conv1D(filters=64, kernel_size=5, activation='relu', padding='same'),
6     layers.MaxPooling1D(pool_size=2),
7     layers.Conv1D(filters=128, kernel_size=3, activation='relu', padding='same'),
8     layers.GlobalAveragePooling1D(),
9     layers.Dense(64, activation='relu'),
10    layers.Dropout(0.3),
11    layers.Dense(NUM_CLASSES, activation='softmax')
12 ])
13 model.compile(optimizer='adam', loss='sparse_categorical_crossentropy',
    ↪ metrics=['accuracy'])

```

Listing 1: Definición de la CNN 1D en `tools/train_har_cnn.py`.

El modelo se entrena por 50 épocas con *early stopping* y regularización por *dropout* 30 % tras el *Dense* 64. La conversión directa a formato TensorFlow Lite (*float32*) resulta en un modelo de 73 KB, el cual mantiene la precisión original sin degradación por cuantización.

Runtime on-device en TFLite Micro

El blob binario se compila embebido como `const unsigned char` en `lib/har_cnn1d/har_model.c` mediante `xxd -i`. En tiempo de arranque, `har_cnn1d_init` solicita una *arena* de 512 KB en PSRAM vía `heap_caps_aligned_alloc(..., MALLOC_CAP_SPIRAM)` y llama a `har_runner_init` (implementado en C++ en `lib/har_cnn1d/har_model_runner.cpp`), quien construye el intérprete TensorFlow Lite Micro [7, 8] con los *op resolvers* específicos de la red (Conv1D, MaxPool1D, MeanReduce, FullyConnected, Softmax). La API pública `har_cnn1d_push_sample` y el modelo de notificación por FreeRTOS aseguran que la inferencia se ejecute cada dos segundos sin bloquear el resto del sistema. El *callback* `har_result_cb` entrega el *argmax* + probabilidades al módulo de UI y al BLE, y una EMA con histéresis de tres ventanas suaviza la etiqueta mostrada al usuario.

Métricas de validación

La Fig.8 muestra la matriz de confusión generada por `tools/har_confusion.py` sobre el conjunto de validación (20 % del dataset, semilla determinística). La exactitud global alcanza el 95,0 %. La Tabla 7 desglosa la métrica *recall/precision* por clase.




Figura 8: Matriz de confusión de la CNN 1D sobre el conjunto de validación (20 % del dataset propio). El modelo alcanza 95,0 % de exactitud global; la clase *stairs* concentra la mayor tasa de error por sub-representación en el dataset.

Cuadro 7: Recall y precisión por clase del clasificador HAR.

Clase	Recall (%)	Precisión (%)
Rest (reposo)	99	98
Walk (caminar)	96	91
Run (trotar)	92	98
Stairs (escaleras)	55	91
Global (accuracy)	95,0 %	

La caída del *recall* para *stairs* (59 %) se explica por dos factores. Primero, el modelo tiende a clasificar el descenso como *walk* rápido, un error benigno para el usuario. Segundo, la cantidad total de ventanas de la clase es menor que la de *walk* y *run*. La corrección por *bias* de -15% aplicada sobre la salida softmax de la *stairs* compensa parcialmente esta asimetría sin sacrificar la precisión (86 %).

Ciclo de depuración cerrado

Un aporte metodológico del proyecto es el ciclo de *replay* para el HAR. Cada sesión IMU capturada por la aplicación móvil se preserva como `.csv.gz` local, y el script `tools/har_replay.py` permite re-ejecutar el mismo modelo TensorFlow Lite fuera del reloj sobre las mismas trazas, imprimiendo probabilidades y matrices de confusión por sesión. Esto habilitó detectar y corregir un bug notorio en etapas intermedias:

cuando el modelo se entrenó accidentalmente sobre datos a 100 Hz y se desplegaba en el reloj muestreando a 50 Hz, la clase *run* se activaba de forma permanente. El diagnóstico solo fue posible gracias al *replay*, y se resolvió re-entrenando el modelo con datos exclusivamente a 50 Hz de muñeca.


5.5. Aplicación móvil y *backend*

La aplicación Flutter [4] implementa tres pantallas principales (Fig. 2): un *dashboard* biométrico en tiempo real, un flujo de captura de ventanas IMU para *ground truth*, y un registro de sesiones ECG con visualización de la señal filtrada. La conectividad Bluetooth Low Energy vive en `app/lib/services/ble_service.dart` y se apoya en `flutter_blue_plus` [5]. El servicio custom del reloj (0xFF00) expone cuatro características: la de telemetría biométrica (TLV con temperatura, HR, SpO₂, actividad HAR, pasos y batería); la de *stream* IMU crudo activada sólo bajo demanda; la de *stream* ECG con *chunks* de 20 B; y la de comandos de control (iniciar/detener captura, ajustar brillo, entrar a deep sleep). La aplicación suscribe las características relevantes según la pantalla activa, minimizando el consumo de radio del reloj cuando no se está graficando IMU.

El almacenamiento local usa Hive [13] para persistir las mediciones por día y la sesión ECG completa. La sincronización con el *backend* respeta la restricción del plan Firebase Spark —no incluye Cloud Storage— por lo que la traza ECG se comprime con gzip en el propio dispositivo y se sube como *Blob* embebido dentro del documento Firestore correspondiente al usuario y a la fecha; las métricas resumidas (*daily summary*, *weekly rollup*) se almacenan como documentos ligeros dentro de la colección `users/{uid}/summaries/`. Los datos crudos de la IMU no se sincronizan al *cloud*: la única etiqueta que viaja es la actividad clasificada por el reloj. Las reglas Firestore [41] restringen lectura y escritura a `request.auth.uid == userId`, garantizando aislamiento entre usuarios en el mismo proyecto Firebase.

5.6. Mecánica y PCB Carrier v4

La Fig. 9 muestra la Carrier v4 fresada y poblada. Es una placa de dos caras diseñada en KiCad [46] y fabricada por JLCPCB. La cara superior alberga el módulo XIAO ESP32-S3 en *through-hole* bajo la disposición estándar de *pin headers* de 2,54 mm y el conector para el LCD GC9A01 con *touch* CST816S. La cara inferior aloja los *footprints* de los cuatro sensores I²C, el conector de la batería y las trazas hacia los pernos del subsistema ECG. El ruteo se optimizó para respetar las reglas de diseño del ProtoMat (ancho mínimo 0,25 mm, *clearance* 0,25 mm) y para dejar la zona de antena on-board del XIAO libre de cobre en un radio de 8 mm, siguiendo la guía de Seeed Studio [3].



(a) Cara superior con el XIAO ESP32-S3, el LCD y la cadena de energía.

(b) Cara inferior con los cuatro sensores I²C y el conector de batería.

Figura 9: PCB Carrier v4 fresada y poblada. Ambas caras usan pistas de 0,25 mm compatibles con el ProtoMat S64.

La carcasa se diseñó en OpenSCAD/Fusion 360 y se imprimió en PLA con capa de 0,20 mm y 30 % de relleno. Consiste en dos piezas atornilladas por cuatro pernos M3 embutidos, un *lug* lateral integrado para la correa estándar de 20 mm, una ventana óptica alineada con el MAX30102 y dos pernos de acero inoxidable AISI 304 en la contracara que sirven como electrodos del subsistema ECG. Las cotas finales son 17 mm × 74 mm × 93 mm, con un peso total (incluyendo tornillería y pernos) de 115 g.

5.7. Consumo, autonomía y gestión de energía

La Tabla 8 desglosa el consumo típico por subsistema según los *datasheets* de los componentes seleccionados. La medición integrada en la placa se realizó con el propio *fuel gauge* MAX17048 en modo de registro estacionario, comparada con el prototipo previo sobre ESP32-C3 (ver Tabla 9).

Cuadro 8: Consumo típico por subsistema en operación y en modo de bajo consumo, según los *datasheets* correspondientes.


Subsistema	Activo (mA)	Suspend/Off (mA)	Observaciones
XIAO ESP32-S3	30	0,014	Idle FreeRTOS con Wi-Fi off; wake por RTC-GPIO. [2, 34]
LCD GC9A01 backlight	15–20	0,0	PWM LEDC; <i>off</i> completo bajo demanda. [29]
MAX30102 (PPG)	1,1	0,001	0x41=0x80 para modo apagado. [24]
BMI160 (IMU)	0,13	0,003	Comandos ACC_SUSPEND/GYR_SUSPEND. [28]
MAX30205 (temperatura)	0,6	0,001	Modo apagado por bit 0. [22]
AD8232 (ECG)	0,17	0,0	Solo activo durante una sesión ECG (30–60 s). [25]
BLE NimBLE advertising	5 (avg)	—	<i>Advertising interval</i> 1000 ms; <i>modem sleep BT</i> habilitado. [32, 11]

Sobre esta base, la Tabla 9 contrasta el consumo del prototipo actual sobre XIAO ESP32-S3 con el prototipo previo sobre C3 SuperMini. El aumento sistemático del 11–15 % se debe al costo de la arquitectura dual-core del S3 y a los accesos periódicos a la PSRAM externa; queda compensado por la posibilidad de correr el intérprete TFLite Micro con arena de 512 KB completamente en PSRAM.


Cuadro 9: Comparación de consumo de corriente sobre batería entre el prototipo C3 SuperMini y el actual XIAO ESP32-S3 en tres escenarios operativos.

Escenario	C3 (mA)	S3 (mA)	Δ (%)
Peak transitorio (ECG + BLE + display)	69	78	+13
Pantalla ON (navegación normal)	63	70	+11
Pantalla OFF (<i>sport</i> , sin inferencia HAR)	27	31	+15

La curva real de descarga (Fig. 10a) se obtuvo dejando el reloj en modo mixto —pantalla intermitente, HAR activo, BLE conectado— hasta que el fuel gauge indicó 20 % de SoC. La autonomía observada es de aproximadamente 10 h, por sobre la meta de 6 h enunciada en §2. La curva de carga complementaria (Fig. 10b) muestra el ciclo CC/CV del SGM40567 alimentando la batería LiPo de 300 mAh: el reloj alcanza el 90 % de carga en 2,7 h y el 100 % en 4,3 h con corriente CC de 100 mA.



(a) Curva real de descarga en uso mixto.



(b) Curva de carga CC/CV a 100 mA.

Figura 10: Caracterización de la autonomía del prototipo cerrado.

Al pulsar el botón lateral por 3 s, el firmware ejecuta la función de apagado profundo: apaga explícitamente MAX30102, MAX30205 y BMI160 mediante sus comandos de suspensión, cancela el *advertising* BLE, apaga el backlight del LCD, y llama a `esp_deep_sleep_start` configurando el botón lateral como *wake source* vía RTC-GPIO. El consumo residual estimado es de $\sim 15 \mu\text{A}$. El reencendido tarda menos de 2 s desde la pulsación hasta el *watchface* operativo, gracias al arranque en frío del ESP32-S3 sin re-negociación Wi-Fi (que no se usa en el reloj).

5.8. Validación biométrica frente a referencias

La Tabla 10 presenta el detalle de la validación cruzada realizada sobre el prototipo cerrado. Todas las mediciones se realizaron sobre el mismo usuario en las mismas condiciones ambientales, alternando entre SupaClock y el instrumento de referencia con separación temporal de ≤ 5 min.

Cuadro 10: Validación biométrica del prototipo cerrado frente a instrumentos de referencia.

Métrica	Instrumento de referencia	Tolerancia declarada	Error medido
HR (bpm)	Samsung Galaxy Watch 4 [9]	$\leq 3 \%$	$\sim 2 \%$
SpO ₂ (%)	Samsung Galaxy Watch 4 [9]	$\leq 3 \%$	$\sim 2 \%$
Temperatura (°C)	Termómetro digital de contacto	$\leq 0,5 \text{ °C @ } 30\text{--}40 \text{ °C}$	$\Delta = 0,2 \text{ °C (33,1 vs 33,3)}$
Pasos (unidades)	Conteo manual (500 pasos)	$\leq 5 \%$	$\sim 2 \%$
ECG (HRV SDNN)	Galaxy Watch 4 [9] + Pan-Tompkins offline	Coherente en forma y HRV	Onda visualmente similar; HRV varía 5 %

Es importante remarcar el carácter comparativo (no absoluto) de esta tabla: el Galaxy Watch 4 no es un instrumento clínico homologado, aunque sí pasa por procesos de validación internos de Samsung y es reconocido como una referencia razonable en la literatura de consumo [21]. Para chequeos más estrictos se propone en §7 una validación ampliada contra oxímetro Beurer PO 30 [47] y ECG clínico.

5.9. Resultados cuantitativos consolidados

Sintetizando la evidencia expuesta, la Tabla 11 resume los indicadores clave del prototipo cerrado que caracterizan su desempeño como sistema integrado. Los detalles metodológicos de cada indicador quedan documentados en las subsecciones previas.

Cuadro 11: Resumen de resultados cuantitativos del prototipo final.

Indicador	Valor	Fuente / sección
Exactitud HAR global	95,0 % sobre validación	§5.4, Fig. 8
Tamaño modelo TFLite	73 KB float32	§5.4
Arena TFLite Micro	512 KB en PSRAM	§5.4
Parámetros modelo	$\sim 44\text{k}$	§5.4, Listing 1
Autonomía uso mixto	$\sim 10 \text{ h}$ hasta 20 % SoC	§5.7, Fig. 10a
Consumo deep sleep	$\sim 15 \mu\text{A}$	§5.7
Peso cerrado	115 g	§3.1
Dimensiones cerradas	$17 \times 74 \times 93 \text{ mm}$	§3.1
Error HR vs Galaxy Watch 4	$\sim 2 \%$	§5.8
Error SpO ₂ vs Galaxy Watch 4	$\sim 2 \%$	§5.8
Error pasos vs conteo manual	$\sim 2 \%$ (500 pasos)	§5.8
Error temperatura vs termómetro	$0,2 \text{ °C @ } 33 \text{ °C}$	§5.8
Costo BOM prototipo	\$ 60.100 CLP	§3, Tabla 4
Latencia BLE mediana	38 ms	§3.2

6. Análisis de impacto de las soluciones y estándares

Esta sección desarrolla la mirada normativa y de impacto del proyecto. Sigue cuatro ejes: las aplicaciones y el impacto socioeconómico, ambiental y en salud pública de un dispositivo como SupaClock; el análisis de riesgo eléctrico según el punto 3 de la norma ECMA-287; la revisión de estándares relevantes al área con las especificaciones adoptadas por el prototipo; y la revisión de la actualidad y solidez de las referencias técnicas empleadas.

6.1. Aplicaciones e impacto socioeconómico, ambiental y en salud

Salud pública.

El proyecto se ubica dentro de la familia de *wearables* de *fitness* pero con un sesgo particular hacia el monitoreo biométrico continuo y de acceso amplio, no hacia la notificación social. Considerando que sólo el 49,7 % de los hombres y el 40,3 % de las mujeres mayores de 18 años en Chile cumplen niveles adecuados de actividad física [14, 15], y que más del 42 % de la población adulta presenta sobrepeso u obesidad [16], un dispositivo compacto que permite auto-monitorizar pasos, HR, SpO₂ y temperatura sin depender de una suscripción *cloud* tiene impacto directo en políticas de promoción de salud cardiovascular y metabólica. Adicionalmente, el modo ECG monoderivación (registro puntual de 30–60 s de la Derivación I) abre la puerta al tamizaje de fibrilación auricular en atención primaria, siguiendo la línea de aplicaciones ya validadas clínicamente en relojes comerciales [21] y de detección algorítmica en Fitbit [48].

Impacto socioeconómico y equidad.

El BOM consolidado en la Tabla 4 alcanza \$60,100 CLP para la versión prototipo, con proyección a menos de \$45,000 CLP en producción de 50 unidades vía SMD y compras al por mayor. Esto contrasta con dispositivos comerciales equivalentes —Apple Watch SE \$250,000 CLP [17], Samsung Galaxy Watch FE \$160,000 CLP [9], Garmin Venu \$200,000 CLP [18]— y con bandas de bajo costo como Mi Band (~\$30,000 CLP), posicionando a SupaClock como una alternativa **de costo medio con potencial de fabricación local**. La evidencia física del prototipo demuestra que la producción de pequeña escala en Chile es viable, sin depender de *contract manufacturing* en Asia. La filosofía de “cero distracciones” adoptada en la interfaz busca **evitar** la carga cognitiva por sobre-notificación descrita en [19, 20], abordando un problema de salud mental relevante que las pulseras genéricas del mercado *exacerban* en lugar de resolver.

Impacto ambiental.

La arquitectura *edge*-céntrica minimiza deliberadamente la transmisión de datos: la clasificación de actividad ocurre en el reloj y no se envían datos crudos de IMU al *cloud*, la telemetría biométrica va a 1 Hz (~ 13 B/s), el ECG solo se transmite durante ventanas puntuales de 30–60 s y las sesiones se comprimen con gzip antes de subirse a Firestore. Esta decisión reduce el *footprint* energético del sistema completo (dispositivo + radio + datacenter), en línea con la literatura reciente de *green AI* para *wearables*. Adicionalmente:

- La selección de componentes prioriza encapsulados **libres de plomo** (RoHS-2, Directiva 2011/65/EU [36]); todos los ICs seleccionados cumplen.
- Se descartó la tecnología *Memory LCD* de Sharp [49] por su alto costo y la *OLED* por su menor durabilidad (burn-in), favoreciendo el IPS LCD circular con vida útil sobre 50,000 h.

- La batería LiPo de 300 mAh se selecciona con PCM integrado (DW01A) y certificación IEC 62133-2 [37], lo que permite un fin de vida controlado y reciclable a través de los puntos de acopio chilenos (Chilenter, MUR).
- La carcasa PLA es biodegradable en condiciones industriales; los pernos AISI 304 y los tornillos M3 son reutilizables y separables al fin de vida del producto.

Aspectos éticos.

El proyecto aborda explícitamente cinco dimensiones éticas.

Privacidad de datos biométricos: las lecturas de HR, SpO₂, temperatura y ECG son *datos sensibles de salud* bajo el espíritu de la Ley 19.628 chilena [39] y el Reglamento General de Protección de Datos europeo (GDPR) [40]. El *backend* Firebase implementado en esta etapa requiere autenticación Google, y las reglas Firestore [41] solamente permiten acceso al propietario mediante `request.auth.uid == userId`. Los datos de ECG quedan asociados al UID del usuario y **nunca al MAC** del dispositivo BLE. No se transmiten datos a terceros distintos del usuario que loguea su sesión.

Limitaciones declaradas como dispositivo no-médico: el sistema se diseña como *wearable de fitness* con el disclaimer explícito de que las mediciones **no constituyen diagnóstico clínico**. No se persigue homologación FDA/ISP. La interfaz muestra un *disclaimer* en la pantalla de ECG del reloj y en la vista correspondiente de la aplicación móvil.

Sesgo en el modelo de Machine Learning: la clasificación HAR (*rest, walk, run, stairs*) se entrenó con datos del propio equipo de desarrollo y voluntarios cercanos, y se declara honestamente en este informe: el dataset es **single-subject dominante** y los rangos de edad, género y índice de masa corporal representados son limitados. La generalización a otros usuarios está auditada mediante la matriz de confusión de la Fig. 8, y su ampliación figura como línea de trabajo futuro. Se optó por una arquitectura CNN 1D relativamente pequeña ($\sim 44k$ parámetros) e interpretable a la salida (probabilidades softmax por clase reportadas junto al argmax) en contraste con enfoques *black-box* más opacos.

Consentimiento informado: el flujo de captura de *ground truth* en la aplicación móvil solicita explícitamente al usuario que declare la clase antes de grabar cada sesión. Todo dato ingresado al modelo tiene esa procedencia explícita, y el usuario puede eliminar sus sesiones en cualquier momento desde la aplicación.

Accesibilidad: el diseño de la UI evita depender del color como único marcador de estado (usa iconografía + texto), utiliza fuente Inter [50] legible y tamaños de letra suficientes para lecturas rápidas al ejercitarse.

6.2. Riesgo eléctrico: análisis ECMA-287 punto 3

La norma **ECMA-287** (*Safety of Electronic Equipment*) [1] establece en su punto 3 (*Electric shock and energy hazards*) los lineamientos para evaluar el peligro de descarga eléctrica y de energía almacenada en equipos electrónicos de consumo. Aplicado a la unidad cerrada de SupaClock, la Tabla 12 presenta el análisis sub-cláusula por sub-cláusula, actualizado al estado final del prototipo (celda LiPo de 300 mAh, no de 250 mAh como en fases anteriores).

Cuadro 12: Análisis de riesgos eléctricos según ECMA-287, punto 3 [1].

Sub-cláusula	Aplicabilidad	Mitigación implementada	Resultado
3.2 <i>Hazardous voltage</i> (>42,4 V AC pico, >60 V DC)	No aplica directamente	Tensiones máximas: 5 V (USB-C IN), 4,2 V (LiPo full), 3,3 V (rail lógico).	Todos los nodos son SELV (Safety Extra-Low Voltage).
3.3 <i>Hazardous energy</i> (≥ 240 VA o ≥ 20 J en 60 s)	Aplica (LiPo 300 mAh = 4,0 kJ)	PCM DW01A [38] integrado en la celda: OCP/UVP/SCP; fusible PTC en el bus de carga; encapsulado con cobertura.	Cortocircuito externo cortado en < 3 ms; sobrecarga limitada a 1 A.
3.4 <i>Working voltage</i>	Aplica al rail 3,3 V	Aislamiento PCB clase FR-4 estándar, distancia mínima 0,25 mm entre pistas digitales. Capa de soldermask en la zona de contacto con el usuario.	Cumple para SELV en interior.
3.5 <i>Insulation requirements</i>	Aplica al contacto con piel	Pernos M3 de ECG en acero inoxidable AISI 304 (no electrolítico), aislados del PCB inferior por carcasa PLA y soldermask. Corriente DC máx. inyectada $\leq 10 \mu\text{A}$ (impedancia in-amp >10 M Ω del AD8232).	Cumple, dentro de límites IEC 60601-1 tipo BF [35].
3.6 <i>Safe touch current</i>	Aplica al chasis	La carcasa es de PLA (aislante); los pernos ECG están eléctricamente flotantes hasta que el usuario cierra el circuito.	Sin riesgo de fuga continua.
3.7 <i>Capacitor discharge</i> (energía almacenada >0,2 J)	Aplica al banco de desacople	Capacitancia total estimada $\sim 47 \mu\text{F}$ a 3,3 V $\rightarrow 0,26$ mJ ($\ll 0,2$ J).	Cumple por holgura de tres órdenes de magnitud.

Se destaca que la energía almacenada en la celda (4,0 kJ para 300 mAh a 3,7 V) sitúa al proyecto en el régimen de *hazardous energy* contemplado por 3.3, pero la mitigación se aborda con la protección integrada por DW01A en la propia celda (OCP a ~ 3 A, UVP a 2,5 V, SCP con corte < 3 ms) y por el cargador SGM40567 con límite de corriente de carga programado a 100 mA. La corriente inyectada al usuario por el AD8232 es despreciable (~ 100 pA a 10 MHz de impedancia diferencial), y la carcasa PLA actúa como aislante mecánico y eléctrico. Se aplican además, sin ser exigidas explícitamente por ECMA-287, las buenas prácticas de IEC 62133-2 [37] para celdas secundarias: protección contra sobrecarga (>4,25 V), sobre-descarga (<2,5 V), inversión de polaridad (diodo Schottky en cabecera de carga) y protección térmica indirecta vía el termistor NTC del PCM. En síntesis, todas las sub-cláusulas del punto 3 se cumplen para la unidad cerrada final.

6.3. Estándares relacionados con el área del proyecto

Además de ECMA-287, se identificaron y adoptaron seis estándares del área electrónica y biomédica cuyas especificaciones específicas se aplicaron sobre el prototipo. Cada uno se enuncia con la especificación clave adoptada, sirviendo tanto para respaldar decisiones de diseño como para orientar una eventual homologación futura.

Bluetooth Core Specification v5.3 [32].

El servicio custom de SupaClock se implementa sobre la pila NimBLE [11] respetando los parámetros de la especificación: se selecciona LE 1M PHY como *phy* primario para asegurar compatibilidad con teléfonos $\geq$ Android 5.0; el *connection interval* se fija en 15 ms y el *slave latency* en 4 para reducir el consumo en el estado idle del reloj; el MTU se negocia a 247 B para minimizar el *overhead* en *chunks* de ECG y en telemetría agregada; el *advertising interval* se configura a 1000 ms para minimizar la actividad de radio en estado no conectado; el *modem sleep BT* de Espressif se habilita para suspender el controlador entre eventos; y el *pairing* usa *Just Works* sin *bonding* para facilitar la reconexión desde herramientas de desarrollo y validación cruzada. Los servicios estándar Device Information (0x180A) [51] y Battery Service (0x180F) [52] se publican junto con el custom 0xFF00 que aloja las cuatro características propias.

IEEE 11073-10406 (*Personal Health Devices — Basic ECG*) [23].

Este estándar especifica las propiedades mínimas de un ECG personal monitorizado: rango ± 5 mV, ruido referido a entrada $< 30 \mu V_{pp}$, ancho de banda 0,05–40 Hz, y tasa de muestreo ≥ 250 Hz para diagnóstico básico. SupaClock cumple parcialmente: el AD8232 entrega 0,5–40 Hz con ganancia ~ 1100 , la decimación a 500 Hz supera holgadamente el mínimo, pero el modo de derivación es *single-lead* (Lead I bimanual) por lo que el dispositivo se declara como **ECG personal de tamizaje**, no de Holter. Las trazas capturadas se procesan con Pan-Tompkins [12] y se etiquetan con el disclaimer no-médico exigido.

IEC 60601-1 (*Medical electrical equipment*) tipo BF [35].

Aunque SupaClock no se homologa como dispositivo médico, se adoptan voluntariamente los criterios de **aislamiento de paciente tipo BF** para el subsistema ECG: el front-end AD8232 presenta impedancia de entrada $> 10 M\Omega$ y corriente de fuga DC $< 10 \mu A$, dentro del límite BF de $100 \mu A$. Esto permite que versiones futuras del proyecto sean presentadas a homologación con cambios menores. La declaración tipo BF se comunica al usuario en la documentación del proyecto.

USB Type-C Cable and Connector Specification, Rev. 2.3 [53].

El conector USB-C del prototipo opera en modo *legacy* 5 V/500 mA (USB 2.0). El módulo SGM40567 declara compatibilidad con esta categoría y limita la corriente de carga a 100 mA por defecto. Para la versión Pro se evalúa soportar 5 V/1,5 A configurando el CC pull-down a 22 k Ω , lo que ahorraría ~ 40 % del tiempo de carga.

RoHS-2 (Directiva 2011/65/EU) [36].

Todos los componentes electrónicos seleccionados cumplen RoHS-2 en tanto encapsulados libres de plomo. La declaración de conformidad de cada IC (Espressif, Bosch Sensortec, Analog Devices/Maxim Integrated, SG Micro) está disponible en las hojas de datos correspondientes.

IEC 62133-2 [37].

La celda LiPo seleccionada (300 mAh con PCM DW01A integrado [38]) cumple los requisitos de seguridad exigibles a baterías secundarias litio-ion para uso portable, incluyendo protecciones OCP/UVF/SCP/OTP y encapsulado metálico. Esto **re-refuerza** el análisis de §6.2 en la sub-cláusula 3.3.

6.4. Referencias y fuentes técnicas

La bibliografía de este informe consolida cerca de 80 entradas correspondientes a: *datasheets* de los componentes electrónicos seleccionados y de las alternativas evaluadas y descartadas (Espressif, Bosch Sensortec, Analog Devices, Sitronix, Galaxycore, Hynitron, SG Micro, Fortune Semiconductor); manuales oficiales de *firmware* y *stacks* de comunicación (ESP-IDF, FreeRTOS, LVGL, NimBLE, TensorFlow Lite Micro, Flutter, Hive, ESP-DSP, ESP-NN); normas técnicas y regulatorias del área electrónica y biomédica (ECMA-287, IEC 60601-1, IEEE 11073-10406, USB-C Rev. 2.3, RoHS-2, IEC 62133-2, Bluetooth Core Specification 5.3); literatura académica sobre HAR con redes neuronales convolucionales (Anguita 2013 [54], Ordóñez y Roggen 2016 [55], Ronao y Cho 2016 [26], Ignatov 2018 [27], Njoku et al. 2024 [56]) y TensorFlow Lite Micro (David et al. 2021 [8]); algoritmos biomédicos clásicos y de vanguardia (Pan-Tompkins 1985 [12], Hamilton 2002 [57], Kazemi 2021 [58], motion artifact SVD 2020 [59]); estadísticas y fuentes de salud pública chilena (Encuesta Nacional de Actividad Física CIPER [14], ENS del MINSAL [15], UC Christus [16]); referencias industriales y comparativas de *wearables* comerciales (Apple Watch [17], Samsung Galaxy Watch 4 [9], Garmin Venu [18], Fitbit AF [48], Samsung BioActive [60]); herramientas de diseño (KiCad [46], LPKF ProtoMat [61], XIAO Pinout [3], Inter Font [50], JPEGDEC [62], lv_font_conv [63]); y fuentes de contexto ético y de comportamiento (Kushlev 2016 [19], Pielot 2014 [20], Shin 2019 [21]). Todas las URLs de las fuentes en línea fueron verificadas al 10 de julio de 2026.

7. Conclusiones y trabajo futuro

7.1. Cumplimiento del alcance planteado

Al cierre del capstone, el equipo entrega un producto integrado que cubre las cinco cadenas biométricas comprometidas al inicio del proyecto (temperatura de piel, frecuencia cardíaca, saturación de oxígeno, electrocardiograma monoderivación y actividad física), lo hace con arquitectura propia extremo a extremo (firmware, PCB, carcasa, modelo entrenado, aplicación móvil y *backend*) y cumple 11 de 12 especificaciones auditadas (Tabla 3). Los indicadores cuantitativos resumidos en la Tabla 11 superan las metas: la autonomía observada duplica el mínimo declarado; la latencia BLE mediana es un tercio del límite; el peso queda por debajo del envoltorio ergonómico; y las métricas biométricas se contrastan con instrumentos comerciales de referencia con errores del orden del 2 %. La única desviación formal es el volumen envoltorio (117 cm³ vs. 90 cm³ objetivo), documentada honestamente en §3.2. En materia de *machine learning*, la exactitud global del 95,0 % del clasificador HAR representa un avance sustancial respecto de la línea base heurística (basada en varianza de $|\vec{a}|$) y valida la viabilidad de correr TFLite Micro con arena de 512 KB en la PSRAM del ESP32-S3.

7.2. Lecciones aprendidas

El proyecto deja cinco lecciones metodológicas relevantes. Primero, entrenar un modelo de actividad física sobre datos capturados en la muñeca —y a la misma frecuencia de despliegue (50 Hz)— es crítico. Un bug intermedio en el que el modelo se entrenó accidentalmente sobre datos a 100 Hz y se desplegó a 50 Hz produjo una activación permanente de la clase *run*, sólo detectada gracias al ciclo de *replay* con `tools/har_replay.py`. Segundo, el ciclo de depuración cerrado —captura por BLE, persistencia local, *replay* en PC y comparación directa contra la matriz de confusión— es una inversión que devuelve un enorme dividendo en visibilidad. Tercero, la contención de costos se logró combinando FabLab local (fresado LPKF), módulos SMD prefabricados (XIAO ESP32-S3, LCD con *touch*, sensores) y compras al por menor a proveedores accesibles. Cuarto, para PCB compactas con radio integrada BLE, respetar las zonas libres de cobre alrededor de la antena on-board del módulo (Seeed XIAO en este caso) es un requisito no negociable. Quinto y finalmente, la elección de PSRAM externa como *hosting* de la arena TFLite Micro fue lo que hizo posible el modelo actual: intentos previos con arena en SRAM interna fallaban con `AllocateTensors` `kTfLiteError` incluso para redes más pequeñas, y la migración de C3 a S3 se justificó precisamente por esta necesidad.

7.3. Trabajo futuro

Cinco líneas se proponen para versiones sucesoras del proyecto. La ampliación del *dataset* HAR a múltiples usuarios y agregar la clase *descender escaleras* corregiría el sesgo del *single-subject* y elevaría el *recall* de la clase *stairs*, hoy en 59 %. La integración de la señal de frecuencia cardíaca como canal secundario del HAR aportaría información fisiológica complementaria que robustecería la frontera entre *walk* rápido y *run*. La detección real de caídas con *dataset* de impacto controlado en colchoneta y un modelo dedicado habilitaría esta función de seguridad. Un modelo liviano de *wrist-up gesture* para el encendido automático de la pantalla reduciría las interacciones manuales innecesarias. Por último, para una versión Pro se propone iniciar el proceso de conformidad IEC 60601-1 tipo BF, con *lab tests* de fuga DC y de aislamiento en instituciones acreditadas.

Referencias

- [1] ECMA International. ECMA-287: Safety of electronic equipment, 2nd ed., 2002. Disponible en: https://ecma-international.org/wp-content/uploads/ECMA-287_2nd_edition_december_2002.pdf.
- [2] Espressif Systems. ESP32-S3 Series Datasheet, Rev. 2024, 2024. URL https://www.espressif.com/sites/default/files/documentation/esp32-s3_datasheet_en.pdf.
- [3] Seeed Studio. *Seeed XIAO ESP32-S3 Schematic & Pinout Reference v1.4*, 2026.
- [4] Google Flutter Team. Flutter Documentation, 2024. Disponible en: <https://docs.flutter.dev/>.
- [5] Charles Crete and contributors. flutter_blue_plus: Bluetooth Low Energy plugin for Flutter, 2024. Disponible en: https://pub.dev/packages/flutter_blue_plus.
- [6] Google. *Firebase Documentation: Authentication, Firestore and Security Rules*, 2024. Disponible en: <https://firebase.google.com/docs>.
- [7] Google TensorFlow Team. *TensorFlow Lite for Microcontrollers*, 2024. Disponible en: <https://www.tensorflow.org/lite/microcontrollers>.
- [8] Robert David, Jared Duke, Advait Jain, Vijay Janapa Reddi, Nat Jeffries, Jian Li, Nick Kreeger, Ian Nappier, Meghna Natraj, Shlomi Regev, Rocky Rhodes, Tiezheng Wang, and Pete Warden. Tensorflow lite micro: Embedded machine learning for TinyML systems. In *Proceedings of Machine Learning and Systems (MLSys)*, volume 3, pages 800–811, 2021. arXiv:2010.08678.
- [9] Samsung Electronics. Samsung Galaxy Watch 4: Product Page, 2021. Referencia usada para validación biométrica cruzada (HR/SpO₂/ECG).
- [10] Espressif Systems. ESP-DSP Library, 2024. URL <https://github.com/espressif/esp-dsp>.
- [11] Apache Software Foundation. *Apache Mynewt NimBLE: Bluetooth Low Energy Stack*, 2024. Disponible en: <https://mynewt.apache.org/latest/network/>.
- [12] Jiapu Pan and Willis J. Tompkins. A real-time qrs detection algorithm. *IEEE Transactions on Biomedical Engineering*, BME-32(3):230–236, 1985. doi: 10.1109/TBME.1985.325532.
- [13] Hive Authors. Hive: Lightweight and blazing fast key-value database for Flutter, 2024. URL <https://pub.dev/packages/hive>.
- [14] CIPER Chile. Resultados de la encuesta nacional de actividad física y deporte: una oportunidad para fortalecer el bienestar integral en chile, 2025. Disponible en: <https://www.ciperchile.cl/2025/05/24/resultados-de-la-encuesta-nacional-de-actividad-fisica-y-deporte/>.
- [15] Ministerio de Salud de Chile. MINSAL: Encuesta Nacional de Salud (ENS) 2016–2017 — Primeros resultados, 2017. Disponible en: https://www.minsal.cl/wp-content/uploads/2017/11/ENS-2016-17_PRIMEROS-RESULTADOS.pdf.
- [16] UC Christus. 5 razones por las que chile es el país con más obesidad de latinoamérica, 2025. Disponible en: <https://www.ucchristus.cl/blog-salud-uc/articulos/2025/5-razones-por-las-que-chile-es-el-pais-con-mas-obesidad-de-latinoamerica>.
- [17] Apple Inc. Apple Watch: Compare Models, 2024. Disponible en: <https://www.apple.com/watch/compare/>.
- [18] Garmin International. Garmin Venu 4: Product Specifications, 2024. Disponible en: <https://www.garmin.com/en-US/p/1614061/>.

- [19] Kostadin Kushlev, Jason Proulx, and Elizabeth W. Dunn. Silence your phones: Smartphone notifications increase inattention and hyperactivity symptoms. In *Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems*, pages 1011–1020, 2016. doi: 10.1145/2858036.2858359.
- [20] Martin Pielot, Karen Church, and Rodrigo de Oliveira. An in-situ study of mobile phone notifications. In *16th International Conference on Human-Computer Interaction with Mobile Devices & Services (MobileHCI)*, pages 233–242, 2014. doi: 10.1145/2628363.2628364.
- [21] G. Shin, M.C. Jarrahi, Y. Fei, and A. Karami. Wearable activity trackers, accuracy, adoption, acceptance and health impact. *Biomedical Engineering Letters*, 9(1):45–52, 2019. doi: 10.1007/s13534-018-0091-2.
- [22] Analog Devices (Maxim Integrated). MAX30205: Human Body Temperature Sensor, 2016. Disponible en: <https://www.analog.com/media/en/technical-documentation/data-sheets/MAX30205.pdf>.
- [23] IEEE Standards Association. IEEE 11073-10406: Health informatics — Personal health device communication — Device specialization — Basic electrocardiograph (ECG), 2011. Disponible en: <https://standards.ieee.org/ieee/11073-10406/4716/>.
- [24] Analog Devices (Maxim Integrated). MAX30102: High-Sensitivity Pulse Oximeter and Heart-Rate Sensor for Wearable Health, 2018. Disponible en: <https://www.analog.com/media/en/technical-documentation/data-sheets/MAX30102.pdf>.
- [25] Analog Devices. AD8232: Single-Lead, Heart Rate Monitor Front End, 2012. Disponible en: <https://www.analog.com/media/en/technical-documentation/data-sheets/ad8232.pdf>.
- [26] Charissa Ann Ronao and Sung-Bae Cho. Human activity recognition with smartphone sensors using deep learning neural networks. *Expert Systems with Applications*, 59:235–244, 2016. doi: 10.1016/j.eswa.2016.04.032.
- [27] Andrey Ignatov. Real-time human activity recognition from accelerometer data using convolutional neural networks. *Applied Soft Computing*, 62:915–922, 2018. doi: 10.1016/j.asoc.2017.09.027.
- [28] Bosch Sensortec. BMI160: Small, Low Power Inertial Measurement Unit, 2020. Disponible en: <https://www.bosch-sensortec.com/media/boschsensortec/downloads/datasheets/bst-bmi160-ds000.pdf>.
- [29] Galaxycore. GC9A01: 240 x 240 Dot Matrix LCD Driver, 2019. Disponible en: <https://www.buydisplay.com/download/ic/GC9A01A.pdf>.
- [30] Hynitron Microelectronics. CST816S: Capacitive Touch Controller Datasheet, 2020. Datasheet interno del fabricante para pantallas circulares 1,28".
- [31] LVGL LLC. *LVGL: Light and Versatile Graphics Library, v8.4*, 2024. Disponible en: <https://docs.lvgl.io/8.4/>.
- [32] Bluetooth SIG. Bluetooth Core Specification v5.3, 2021. Disponible en: <https://www.bluetooth.com/specifications/specs/core-specification-5-3/>.
- [33] Analog Devices (Maxim Integrated). MAX17048/MAX17049: Micropower 1-Cell/2-Cell Li+ Fuel Gauge with ModelGauge, 2013. Disponible en: <https://www.analog.com/media/en/technical-documentation/data-sheets/MAX17048-MAX17049.pdf>.
- [34] Espressif Systems. *ESP-IDF Programming Guide v5.x — Sleep Modes*, 2024. URL https://docs.espressif.com/projects/esp-idf/en/latest/esp32s3/api-reference/system/sleep_modes.html.

- [35] International Electrotechnical Commission. IEC 60601-1: Medical electrical equipment — Part 1: General requirements for basic safety and essential performance, 2020. Norma internacional, Ed. 3.2.
- [36] European Parliament and Council. Directive 2011/65/EU (RoHS 2): Restriction of the use of certain hazardous substances in electrical and electronic equipment, 2011. Diario Oficial L 174, 1 de julio de 2011.
- [37] International Electrotechnical Commission. IEC 62133-2: Secondary cells and batteries — Safety requirements for portable lithium systems, 2017. Norma para celdas LiPo de uso portátil.
- [38] Fortune Semiconductor. DW01A: One Cell Lithium-ion/Polymer Battery Protection IC, 2014. Disponible en: <https://www.fortune-semi.com/upload/files/dw01a.pdf>.
- [39] Biblioteca del Congreso Nacional de Chile. Ley 19.628 sobre Protección de la Vida Privada, 1999. Disponible en: <https://www.bcn.cl/leychile/navegar?idNorma=141599>.
- [40] European Parliament and Council. Regulation (EU) 2016/679 (General Data Protection Regulation), 2016. Diario Oficial L 119, 4 de mayo de 2016.
- [41] Google. Cloud Firestore Security Rules, 2024. Disponible en: <https://firebase.google.com/docs/firestore/security/get-started>.
- [42] Microchip Technology. MCP73831/2: Miniature Single-Cell, Fully Integrated Li-Ion, Li-Polymer Charge Management Controllers, 2014. Disponible en: <https://ww1.microchip.com/downloads/en/DeviceDoc/20001984g.pdf>.
- [43] SG Micro Corp. SGM40567: 5V Input, 1A Linear Battery Charger, 2022. Disponible en: <https://www.sg-micro.com/uploads/soft/20221108/1667891935.pdf>.
- [44] SG Micro Corp. SGM6029: Synchronous Step-Down DC/DC Converter, 2020. Disponible en: <https://www.sg-micro.com/uploads/soft/20200604/SGM6029.pdf>.
- [45] Amazon Web Services. *FreeRTOS Reference Manual*, 2024. Disponible en: https://www.freertos.org/Documentation/RTOS_book.html.
- [46] KiCad project team. KiCad EDA, v8.x, 2024. Disponible en: <https://www.kicad.org>.
- [47] Beurer GmbH. Beurer PO 30: Pulse Oximeter — User Manual, 2022. Disponible en: <https://www.beurer.com/>.
- [48] PACE-CME. Novel algorithm using irregular heart rhythm detection by Fitbit wearables for AF screening, 2021. Disponible en: <https://pace-cme.org/news/novel-algorithm-using-irregular-heart-rhythm-detection-by-fitbit-wearables-for-af-screening/2456100/>.
- [49] Sharp Microelectronics. LS013B7DH03: Memory LCD Data Sheet, 2014. Disponible en: https://www.sharpsma.com/documents/20181/0/LS013B7DH03_Spec.pdf.
- [50] Rasmus Andersson et al. Inter font family v3.19, 2023. URL <https://github.com/rsms/inter>.
- [51] Bluetooth SIG. Bluetooth SIG: Device Information Service (DIS) 1.1, 2011. UUID asignado 0x180A. Disponible en: <https://www.bluetooth.com/specifications/specs/device-information-service-1-1/>.
- [52] Bluetooth SIG. Bluetooth SIG: Battery Service (BAS) 1.0, 2011. UUID asignado 0x180F. Disponible en: <https://www.bluetooth.com/specifications/specs/battery-service-1-0/>.

- [53] USB Implementers Forum. USB Type-C Cable and Connector Specification, Rev. 2.3, 2023. Disponible en: <https://www.usb.org/document-library/usb-type-cr-cable-and-connector-specification-release-23>.
- [54] Davide Anguita, Alessandro Ghio, Luca Oneto, Xavier Parra, and Jorge L. Reyes-Ortiz. A public domain dataset for human activity recognition using smartphones. In *21st European Symposium on Artificial Neural Networks (ESANN)*, 2013. UCI HAR dataset. Disponible en: <https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones>.
- [55] Francisco Javier Ordoñez and Daniel Roggen. Deep convolutional and lstm recurrent neural networks for multimodal wearable activity recognition. *Sensors*, 16(1):115, 2016. doi: 10.3390/s16010115.
- [56] Jude Nwadiuto Njoku, Manuel Estrada, Sebastian Ma, Zixian Zhong, Rafi Ibn Sultan Chowdhury, et al. Deep learning-based human activity recognition on edge devices: A benchmark analysis. In *IEEE International Conference on Communications (ICC)*, 2024. Disponible en: <https://arxiv.org/abs/2307.09424>.
- [57] Patrick S. Hamilton. Open source ecg analysis software documentation. *EP Limited*, 2002. Disponible en: <http://www.eplimited.com/osea13.pdf>.
- [58] K. Kazemi et al. Robust PPG Peak Detection Using Dilated Convolutional Neural Networks. *Sensors*, 2021. Disponible en: <https://www.mdpi.com/1424-8220/22/16/6054>.
- [59] J. Lee et al. Motion Artifact Reduction in Wearable Photoplethysmography Based on Multi-Channel Sensors with Multiple Wavelengths. *Sensors*, 2020. Disponible en: <https://www.mdpi.com/1424-8220/20/5/1493>.
- [60] Samsung Developers. Samsung BioActive Sensor: Overview, 2024. Disponible en: <https://developer.samsung.com/health/sensor/overview.html>.
- [61] LPKF Laser & Electronics AG. *ProtoMat S64 User Manual and Design Rules*, 2023.
- [62] Larry Bank. JPEGDEC: An optimized JPEG decoder for Arduino and other embedded platforms, 2023. Disponible en: <https://github.com/bitbank2/JPEGDEC>.
- [63] LVGL Project. lv_font_conv: Tool for converting fonts to lvgl bitmap format, 2024. URL https://github.com/lvgl/lv_font_conv.

A. Anexos: extractos de código y tablas

A.1. Extracto del pinmap centralizado (include/supaclock_pinmap.h)

El Listado 2 muestra la centralización de asignaciones de GPIO en el firmware para el XIAO ESP32-S3. Todos los subsistemas consumen estas macros, evitando la dispersión de constantes mágicas.

```
1  /* ----- I2C compartido (BMI160, MAX30102, MAX30205, MAX17048) ----- */
2  #define SUPA_PIN_I2C_SDA          5
3  #define SUPA_PIN_I2C_SCL          6
4
5  /* ----- SPI para GC9A01 1.28" circular ----- */
6  #define SUPA_PIN_SPI_MOSI         9
7  #define SUPA_PIN_SPI_SCK          7
8  #define SUPA_PIN_SPI_CS           44
9  #define SUPA_PIN_SPI_DC           4
10 #define SUPA_PIN_LCD_RST           (-1) /* reset por software */
11 #define SUPA_PIN_LCD_BLK           3    /* LEDC PWM */
12
13 /* ----- CST816S touch capacitivo ----- */
14 #define SUPA_PIN_TOUCH_INT         2
15 #define SUPA_PIN_TOUCH_RST         21
16
17 /* ----- AD8232 ECG ----- */
18 #define SUPA_PIN_ECG_OUT           1    /* ADC1_CH0 (S3) */
19 #define SUPA_PIN_ECG_SDN           2    /* shutdown activo alto */
20 #define SUPA_ADC_CHANNEL_ECG       ADC_CHANNEL_0
21 #define SUPA_ADC_UNIT_ECG          ADC_UNIT_1
22
23 /* ----- Botones ----- */
24 #define SUPA_PIN_BTN_SELECT         8    /* wake por RTC-GPIO */
25
26 /* ----- IMU INT1 (BMI160) ----- */
27 #define SUPA_PIN_BMI160_INT1       (-1) /* no cableada en carrier v4 */
```

Listing 2: Definiciones de GPIO en include/supaclock_pinmap.h.

A.2. API pública del HAR CNN 1D (lib/har_cnn1d/har_cnn1d.h)

El Listado 3 muestra la API pública del subsistema HAR consumida por el resto del firmware. La constante HAR_WINDOW_SIZE = 200 corresponde a 4s $\times$ 50 Hz, y HAR_HOP_SIZE = 100 equivale a 2s.

```
1  #define HAR_WINDOW_SIZE           200
2  #define HAR_HOP_SIZE              100
3  #define HAR_CHANNELS              6
4  #define HAR_NUM_CLASSES           4
5
6  typedef enum {
7      HAR_STATE_REST = 0,
8      HAR_STATE_WALK,
9      HAR_STATE_RUN,
10     HAR_STATE_STAIRS,
11     HAR_STATE_UNKNOWN
12 } har_state_t;
13
14 typedef struct {
15     har_state_t state;
16     float confidence;
17     float probs[HAR_NUM_CLASSES];
```

```

18     bool fall_event;                /* OBSOLETO tras rediseño a stairs */
19     int64_t timestamp_us;
20 } har_result_t;
21
22 typedef void (*har_result_cb_t)(const har_result_t *r, void *user);
23
24 esp_err_t har_cnn1d_init(har_result_cb_t cb, void *cb_user);
25 void      har_cnn1d_pause(void);
26 void      har_cnn1d_resume(void);
27 har_result_t har_cnn1d_last(void);
28 size_t     har_cnn1d_arena_used(void);
29 void      har_cnn1d_push_sample(int16_t ax, int16_t ay, int16_t az,
30                                int16_t gx, int16_t gy, int16_t gz);

```

Listing 3: API pública del HAR CNN 1D.

A.3. Snippet de inferencia HAR sobre ventana IMU

El Listado 4 muestra el núcleo de la función `run_inference_on_window` en `lib/har_cnn1d/har_cnn1d.c`: invocación al *runner* TFLite Micro, caída a la ventana previa como *fallback* suave si un *invoke* individual falla, y logging *throttled*.

```

1  static void run_inference_on_window(void) {
2      float probs[HAR_NUM_CLASSES] = {0};
3      bool ok = false;
4
5      if (s_runner_ready && har_runner_run) {
6          ok = har_runner_run((const int16_t (*)[HAR_CHANNELS])s_ring, probs);
7          if (!ok && s_last_result.state != HAR_STATE_UNKNOWN) {
8              memcpy(probs, s_last_result.probs, sizeof(probs));
9              ok = true;
10         }
11     }
12     if (!ok) heuristic_infer(probs);
13
14     int argmax = 0;
15     for (int i = 1; i < HAR_NUM_CLASSES; ++i)
16         if (probs[i] > probs[argmax]) argmax = i;
17
18     har_result_t r = {
19         .state      = (har_state_t)argmax,
20         .confidence  = probs[argmax],
21         .timestamp_us = esp_timer_get_time(),
22     };
23     memcpy(r.probs, probs, sizeof(probs));
24     s_last_result = r;
25     if (s_cb) s_cb(&r, s_cb_user);
26 }

```

Listing 4: Núcleo de la inferencia HAR sobre ventana IMU (extracto).

A.4. Extracto del algoritmo FFT de pasos (`lib/step_algorithm/step_algorithm.c`)

El Listado 5 muestra el núcleo del cómputo espectral de pasos sobre el ESP32-S3.

```

1  #if defined(CONFIG_IDF_TARGET_ESP32S3)
2  #include "esp_dsp.h"
3  #define FFT_WINDOW_SIZE 128

```

```

4  uint8_t step_algo_update(step_algo_state_t *state, int16_t ax, int16_t ay,
5                          int16_t az, int16_t gx, int16_t gy, int16_t gz,
6                          uint32_t current_time_ms, bool is_sport_mode) {
7
8      uint8_t new_steps = 0;
9      /* 1) Actualizar buffer de magnitud |a| */
10     float mag = sqrtf((float)ax*ax + (float)ay*ay + (float)az*az);
11     state->buf[state->wr_idx] = mag;
12     state->wr_idx = (state->wr_idx + 1) % FFT_WINDOW_SIZE;
13
14     /* 2) Cada HOP muestras, ejecutar FFT y actualizar pasos */
15     if (++state->samples_since_fft < STEP_HOP_SIZE) return 0;
16     state->samples_since_fft = 0;
17
18     /* Ventana Hann + FFT compleja de 128 puntos v\via ESP-DSP */
19     dsps_wind_hann_f32(state->win, FFT_WINDOW_SIZE);
20     /* ... rellenar arreglo real/imag alternado ... */
21     dsps_fft2r_fc32(state->buf_fft, FFT_WINDOW_SIZE);
22     dsps_bit_rev_fc32(state->buf_fft, FFT_WINDOW_SIZE);
23
24     /* 3) Extraer pico dominante en banda 1.0-2.5 Hz */
25     float f_dom = extract_dominant_freq(state->buf_fft,
26                                       1.0f, 2.5f, SAMPLE_RATE_HZ);
27
28     if (f_dom > 0.0f) {
29         float step_period_ms = 1000.0f / f_dom;
30         if (current_time_ms - state->last_step_ms >= step_period_ms) {
31             new_steps = 1;
32             state->last_step_ms = current_time_ms;
33         }
34     }
35     return new_steps;
36 }
#endif

```

Listing 5: Lógica de cómputo FFT en lib/step_algorithm/step_algorithm.c.

A.5. Repositorio del proyecto

El código fuente completo, la mecánica en OpenSCAD/Fusion 360, el hardware KiCad, el firmware ESP-IDF, la aplicación Flutter, las herramientas de entrenamiento y este informe se encuentran versionados en el repositorio público del proyecto SupaClock del equipo, cuya estructura de directorios de alto nivel es:

```

1  SupaClock/
2      src/          - main.c y punto de entrada del firmware
3      lib/          - drivers y modulos: har_cnn1d, step_algorithm,
4                    bmi160, max30102, max30205, ad8232, max17048,
5                    cst816s, gc9a01, ble_telemetry, supaclock_ui, ...
6      include/      - headers compartidos, supaclock_pinmap.h, config
7      app/          - aplicacion movil Flutter + Firebase (Firestore, Auth)
8      hardware/     - KiCad esquematicos y PCB de la Carrier v4
9      mechanical/   - OpenSCAD/Fusion 360 de la carcasa y renders
10     data_ml/       - dataset propio de HAR: .csv.gz por sesion
11     tools/         - train_har_cnn.py, har_confusion.py, har_replay.py,
12                     gen_grafico_pasos.py, gen_grafico_ecg.py, ...
13     docs/          - avances (Entrega1-4), Entrega Final, datasheets

```

Listing 6: Estructura de directorios del repositorio.